

Plagiarism Scan Report



Characters:4668
Sentences:30

Words:706

Speak Time: 6 Min

Excluded URL

None

Content Checked for Plagiarism

Modelos Lineales Generalizados Mixtos (GLMM) Los Modelos Lineales Generalizados Mixtos (GLMM) son una extensión de los Modelos Lineales Generalizados (GLM) que permiten modelar la relación entre variables predictoras y una variable respuesta, teniendo en cuenta la estructura de dependencia entre las observaciones y la inclusión de efectos aleatorios. Estos modelos resultan especialmente valiosos cuando los datos presentan una estructura jerárquica o correlacionada, como sucede en casos de datos longitudinales, de panel o agrupados, como en nuestra situación donde podemos agrupar los datos por disciplina. La principal ventaja de los GLMM frente a modelos lineales y LMM radica en su capacidad para manejar datos no normales y aun así analizar sus efectos fijos, tal como aborda el autor @bolker2009generalized en su análisis sobre ecología y evolución. Además, los GLMM ofrecen una mayor flexibilidad para modelar diferentes tipos de variables respuesta y estructuras de datos, así como una mejor capacidad para capturar la variabilidad entre grupos. Asimismo, permiten interpretar la varianza residual y descomponerla en componentes atribuibles a los efectos fijos y aleatorios, lo que facilita la interpretación de la variabilidad observada en los datos. Para concluir los GLMM representan una herramienta estadística poderosa y flexible para modelar relaciones entre variables predictoras y una variable respuesta en presencia de estructuras de datos jerárquicas o correlacionadas, y son especialmente útiles en campos como la ecología, la biología, la epidemiología y las ciencias sociales @zuur2009mixed. La fórmula general de los glmm es la siguiente: \myequations{Modelo GLMM} \begin{equation} \large g(\mu_{ij}) = \beta_0 + \beta_1 \cdot x_{ij} + u_{ij}\end{equation} #### Modelo de regresión svr (Support Vector Regression, SVR) La Regresión mediante Máquinas de Vectores de Soporte (SVR) emerge como una técnica innovadora en el ámbito del aprendizaje automático, evolucionando a partir de los principios establecidos por las Máquinas de Vectores de Soporte (SVM) para enfrentar desafíos específicos asociados con tareas de regresión. Este enfoque se distingue por su capacidad para predecir valores continuos, aplicando un marco que equilibra la precisión predictiva con la complejidad del modelo para asegurar la generalización efectiva a datos no vistos. El desarrollo conceptual y teórico de la SVR se apoya en la teoría de optimización y la teoría estadística del aprendizaje, particularmente en los trabajos de Vapnik y sus colaboradores, quienes han sido fundamentales en la formulación de las SVM y, por extensión, de la SVR @Vapnik1995. Central para la metodología de la SVR es la implementación de funciones kernel, que facilitan el mapeo no lineal de los datos de entrada a un espacio de alta dimensión donde las relaciones complejas entre variables pueden ser

modeladas linealmente. Esta característica es esencial para abordar con éxito datos que presentan patrones no lineales, permitiendo que la SVR se adapte a una amplia variedad de contextos y tipos de datos. La selección del kernel adecuado (e.g., lineal, polinomial, RBF) y la calibración de sus parámetros son cruciales para el rendimiento del modelo, enfatizando la importancia de una comprensión detallada de la naturaleza del conjunto de datos y el problema específico a resolver @ScholkopfSmola2002. La formulación general de la Regresión mediante Máquinas de Vectores de Soporte (SVR) busca encontrar una función \$f(x)\$ que tenga a lo más un \$\epsilon\$-desvío de los valores reales \$y i\$ para todas las muestras de entrenamiento, y al mismo tiempo sea lo más plana posible. Matemáticamente, esto se traduce en minimizar la siguiente función objetivo: \myequations{función objetivo de la Regresión SVR} \begin{equation} $\label{large min_{w, b, xi, xi^*} frac_{1}_{2} \left(xi_{i-1}^{n} (xi_i + xi_{i^*}) \right) } $$ \left(xi_i + xi_{i^*} \right) $$ (xi_i + xi_{i^*}) $$ \end{equation} Sujeto a las restricciones: \$\$ \begin{aligned} y_i - \langle w, x_i \rangle b &\leq \epsilon + \xi_i, \\ \langle w, x_i \rangle + b - y_i &\leq \epsilon + \xi_i^*, \\ \xi_i, $x_i^* & geq 0, & text{ para todo } i = 1, \dots, n. \end{aligned} $$ Donde: - x_i son$ las características de entrada, - \$y_i\$ son los valores objetivo, - \$w\$ es el vector de pesos, - \$b\$ es el término de sesgo, - \$\xi_i\$ y \$\xi_i^*\$ son variables de holgura que miden el grado de desviación permitido para errores por encima y por debajo de \$\epsilon\$, respectivamente, - \$C\$ es el parámetro de regularización que establece el balance entre la suavidad de la función \$f(x)\$ y el grado hasta el cual desviaciones mayores que \$\epsilon\$ son toleradas.

Sources



Home Blog Testimonials About Us Privacy Policy

Copyright © 2024 Plagiarism Detector. All right reserved